

Machine Learning Project (Regression Model and Clustering)

Data Scientist

Presented by Nurul Fadilah Syahrul

Batch July 2023





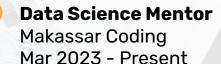
About You

I'm incredibly passionate about learning data science, and it all started with a final project at my campus using R and Tableau. Currently, I'm still exploring various data science tools, including data analysis, preprocessing, visualization, modeling, and forecasting. I'm on an exciting journey to master the art of data science!





My Experiences



Data Science Bootcamp Student Rakamin Academy Nov 2022 - Mar 2023

Tetris ProA - Fast Track Data Analytics DOLab Sep 2022 - Oct 2022

Challenge





- 1. Task 1: Dbeaver Connection with PostgreSQL
- 2. Task 2: Tableau Public Create Dashboard
- 3. Task 3: Machine Learning Regression (Time Series)
- 4. Task 4: Machine Learning Clustering





o query 1 : Berapa rata-rata umur customer jika dilihat dari marital statusnya ?

```
●select
     "Marital Status" as marital status,
     round(avg(age), 2) as avg_age
 from
     customer
 where
     "Marital Status" != ''
 group by
     marital_status
 order by
     avg_age asc
```

	marital_status	T:	¹ãavg_age	•
1	Single		29.38	
2	Married		43.04	





o query 2 : Berapa rata-rata umur customer jika dilihat dari gender nya ?

```
select
    gender,
    round(avg(age), 2) as avg_age
from
    customer
group by
   gender
order by
    avg_age asc
```

	123 gender 👣	¹ãavg_age ₹ ‡
1	1	39.14
2	0	40.33





query 3: Tentukan nama store dengan total quantity terbanyak!

```
select
    st.storename as store_name,
    sum(tr.qty) as quantity
from
   transaction as tr
join
    store as st
    on
        tr.storeid = st.storeid
group by
    store_name
order by
   quantity desc
```

		store_name 😲	¹ quantity ☐ quantity		
	1	Lingga	2,777		
	2	Sinar Harapan	2,588		
	3	Prestasi Utama	1,395		
	4	Prima Kota	1,358		
	5	Buana	1,320		
	6	Prima Tendean	1,310		
١	7	Prima Kelapa Dua	1,296		
h	8	Harapan Baru	1,286		
	9	Bonafid	1,283		
	10	Priangan	1,239		
	11	Gita Ginara	1,236		
	12	Buana Indah	1,208		





o query 4: Tentukan nama produk terlaris dengan total amount terbanyak!

```
select
    pr."Product Name" as product_name,
    sum(tr.totalamount) as total amount
from
   product as pr
join
   transaction as tr
   on
        pr.productid = tr.productid
group by
   product_name
order by
    total amount desc
```

	product_name 👣	¹⁵total_amount 👯
1	Cheese Stick	27,615,000
2	Choco Bar	21,190,400
3	Coffee Candy	19,711,800
4	Yoghurt	19,630,000
5	Oat	15,440,000
6	Crackers	13,680,000
7	Potato Chip	13,104,000
8	Thai Tea	11,982,600
9	Cashew	11,286,000
10	Ginger Candy	8,403,200

Task 2 - Sales Dashboard



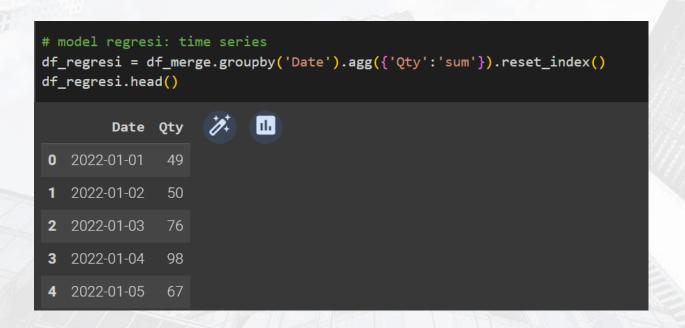








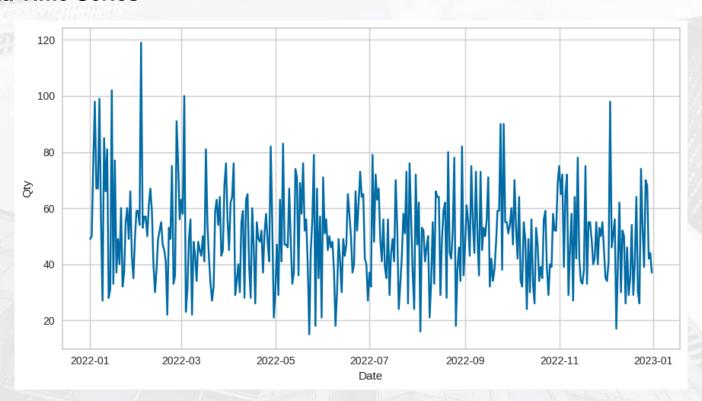
Preview Data







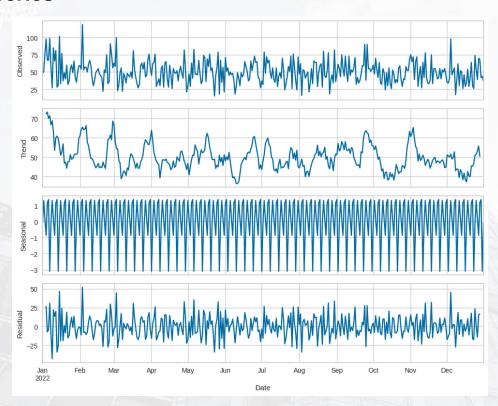
Plot Data Time Series







Plot Data Time Series



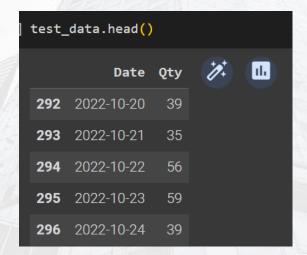




Split Data Time Series

```
# Splitting the data into training and testing sets
train_size = int(len(df_regresi) * 0.8) # 80% data for training, 20% for testing
train_data, test_data = df_regresi.iloc[:train_size], df_regresi.iloc[train_size:]
```



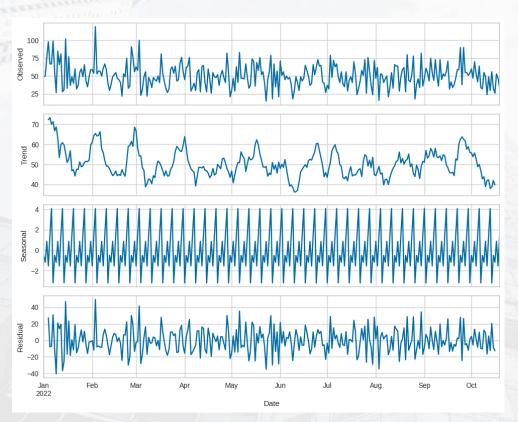


Dilakukan split data train dan data test, data train menggunakan 80% dari keseluruhan data dan data test menggunakan 20% dari keseluruhan data





Plot Data Train Time Series







Uji Stasioner Data Train Time Series

```
# Statistical test to validate stationarity
# Ho = The data is not stationary
# Ha = The data is stationary
alpha = 0.05
adfuller pvalue = adfuller(train_data['Qty'])[1]
if adfuller_pvalue <= alpha:</pre>
    print('Reject Ho. The data is stationary')
    print(adfuller pvalue)
else:
    print('Fail to reject Ho. The data is not stationary')
    print(adfuller pvalue)
Reject Ho. The data is stationary
8.939693654974982e-30
```

Uji ADF di atas menunjukkan bahwa data sudah stasioner. Akan tetapi, plot time series menunjukkan datanya belum stasioner secara musiman. Sehingga, akan dilakukan differencing tiap lag musimannya, yaitu lag 7.





Differencing pada Lag Musiman Data Train Time Series

```
diff mus7 = train data['Qty'].diff(periods = 7)
diff mus7
        NaN
        NaN
        NaN
        NaN
        NaN
287
        1.0
288
      -29.0
289
       4.0
290
       23.0
      -15.0
Name: Qty, Length: 292, dtype: float64
```

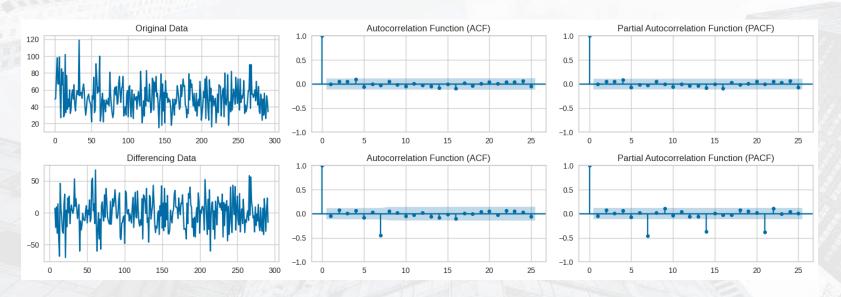
Uji Stasioner

```
# Ho = The data is not stationary
# Ha = The data is stationary
alpha = 0.05
adfuller pvalue = adfuller(diff mus7.dropna())[1]
if adfuller pvalue < alpha:
    print('Reject Ho. The data is stationary')
    print(adfuller pvalue)
else:
    print('Fail to reject Ho. The data is not stationary')
    print(adfuller pvalue)
Reject Ho. The data is stationary
8.752600524789744e-13
```





Plot ACF dan PACF

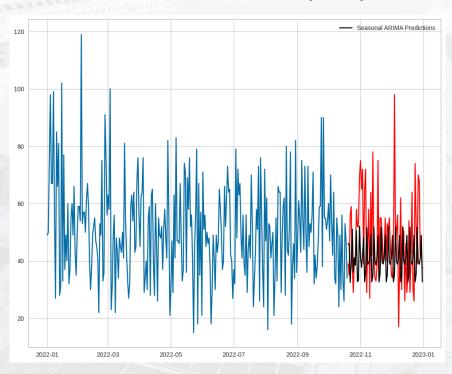


Model Seasonal ARIMA yang terbentuk adalah ARIMA (0, 0, 0) dengan seasonal (0, 1, 1, 7). Akan tetapi, kita juga akan melakukan pengecekan untuk model gabungan MA = 1 dan/atau AR = 1, sehingga model yang mungkin terbentuk adalah model seasonal (0, 1, 1, 7), (1, 1, 0, 7), atau (1, 1, 1, 7).





Plot Model Terbaik: Model ARIMA (0,0,0) Seasonal (1,1,0,7)



RMSE Value: 18.844472452071

R-squared Value: -0.5175525959705869

MAE Value: 14.653489452408634

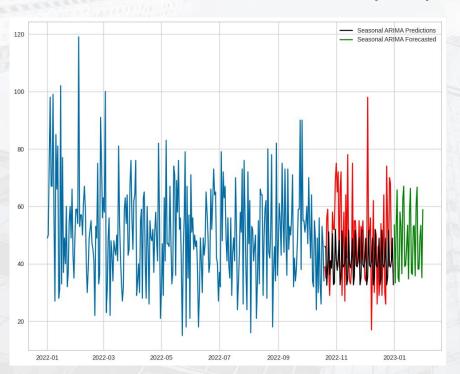
Model ini memenuhi:

- (1) Parameter yang digunakan signifikan
- Asumsi residual: white noise dan berdistribusi normal





Forecast Model Terbaik: Model ARIMA (0,0,0) Seasonal (1,1,0,7)

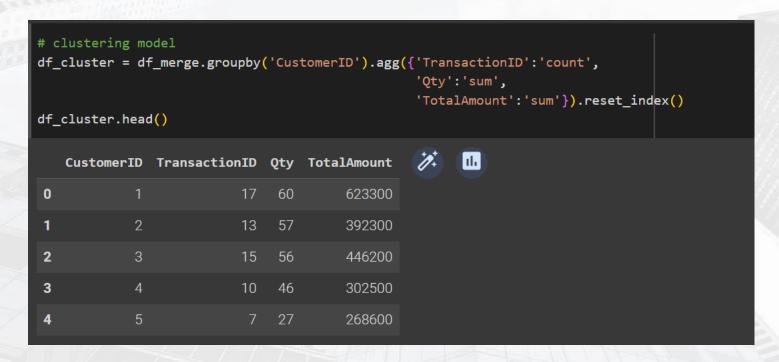


	lower Qty	upper Qty	forecasted Qty
Date			
2023-01-01	17.676142	89.460497	53.568319
2023-01-02	-2.575369	69.208986	33.316808
2023-01-03	17.626566	89.410921	53.518743
2023-01-04	29.834546	101.618901	65.726723
2023-01-05	-0.712008	71.072347	35.180170





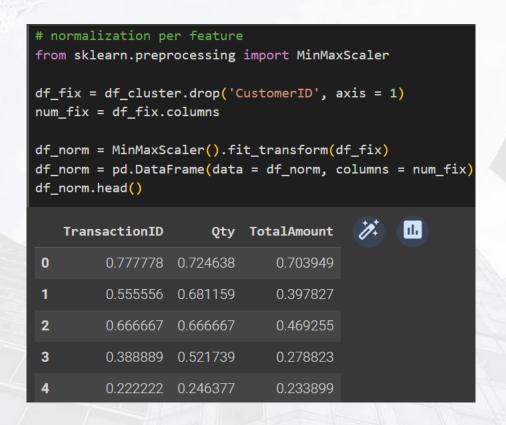
Preview Data







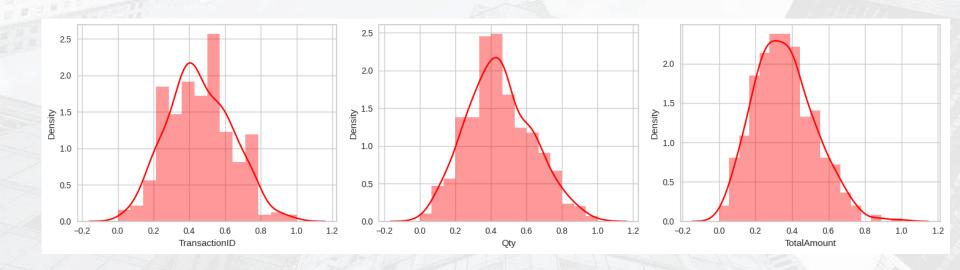
Data Normalization







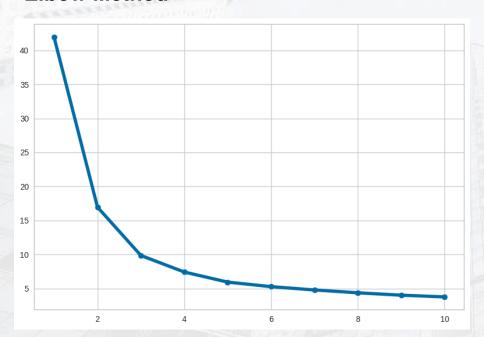
Data Normalization







Elbow Method



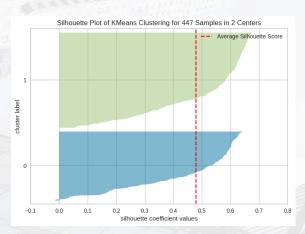
```
pd.Series(inertia) - pd.Series(inertia).shift(-1)
     24.940793
      7.095549
      2.432546
      1.480778
      0.667887
      0.484641
      0.416335
      0.353157
      0.246628
           NaN
dtype: float64
```

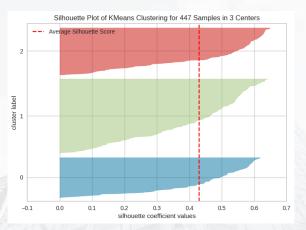
Berdasarkan Elbow Method, jumlah cluster yang sesuai adalah 3 cluster.

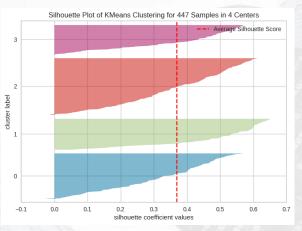




Silhouette Plot







For $n_{\text{clusters}} = 2$, the silhouette score is 0.47981313905566353

For n_clusters = 3, the silhouette score is 0.4301783058437479

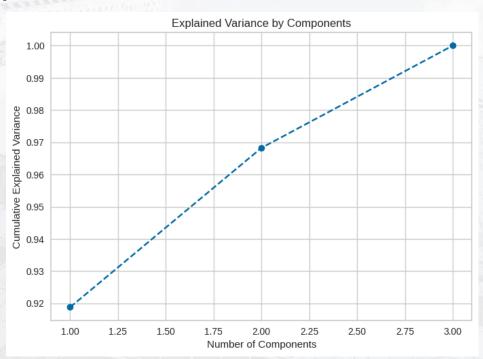
For $n_{clusters} = 4$, the silhouette score is 0.3690791804072523

Berdasarkan keseimbangan tiap cluster dari silhouette plot, jumlah cluster yang optimal adalah 3 cluster. Meskipun rata-rata shilouette score untuk 2 cluster lebih tinggi, kita akan tetap menggunakan 3 cluster untuk pemodelan (dengan mempertimbangkan Elbow Method juga)





PCA

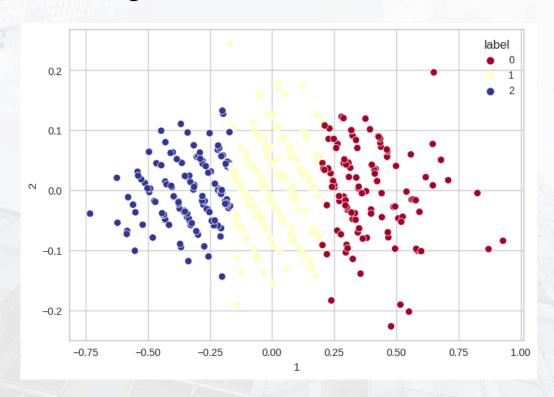


n_components dipilih yang adalah 2 components karena variasi data yang tercover sekitar 90%





Visualisasi Clustering



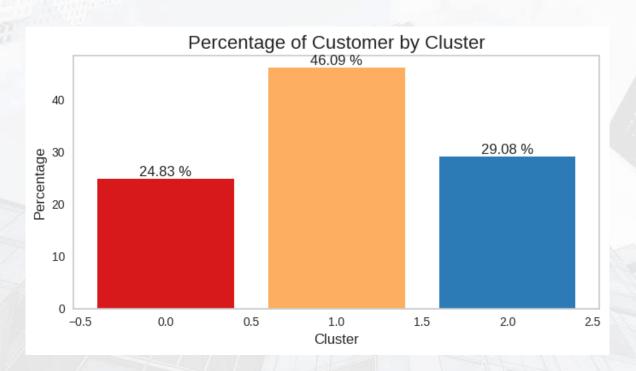




	TransactionID			Qty			TotalAmount						
		count	mean	median	std	count	mean	median	std	count	mean	median	std
	cluster												
	0	111	15.351351	15.0	1.776865	111	57.558559	57.0	7.071948	111	523573.873874	509900.0	81200.111634
	1	206	11.262136	11.0	1.504213	206	40.936893	41.0	5.275891	206	360200.485437	360750.0	55396.873644
П	2	130	7.661538	8.0	1.635620	130	26.723077	27.5	5.866757	130	228653.846154	234550.0	53102.234517
8.													

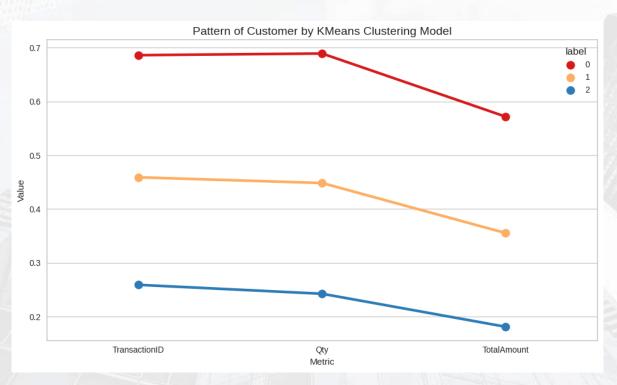






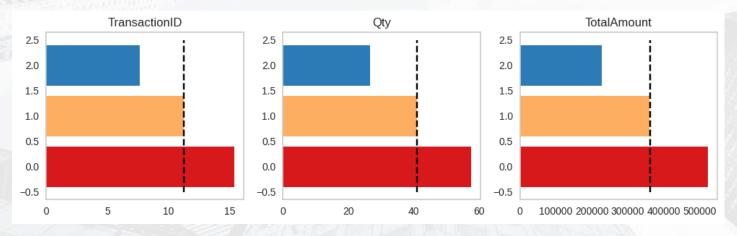












Cluster	High Value	Average Value	Low Value
Cluster 0	TransactionID, Qty, TotalAmount		
Cluster 1		TransactionID, Qty, TotalAmount	
Cluster 2			TransactionID, Qty, TotalAmount





Clustering Interpretation

- Cluster 0 Loyalty Customer
- Terdapat 111 customer (24.83%).
- Customer di kelompok ini memiliki rata-rata transaksi yang tinggi, yaitu sekitar 15 kali transaksi, rata-rata jumlah atau kuantitas produk yang dibeli customer tinggi yaitu sekitar 58 unit produk, dan rata-rata jumlah uang yang dikeluarkan oleh customer tinggi yaitu sekitar 524K.
- Cluster 1 Potential Customer
- Terdapat 206 customer (46.09%)
- Customer di kelompok ini memiliki rata-rata transaksi yang sedang, yaitu sekitar 11 kali transaksi, rata-rata jumlah atau kuantitas produk yang dibeli customer sedang yaitu sekitar 41 unit produk, dan rata-rata jumlah uang yang dikeluarkan oleh customer sedang yaitu sekitar 360K.





Clustering Interpretation

- Cluster 2 New Customer
- Terdapat 130 customer (29.08%)
- Customer di kelompok ini memiliki rata-rata transaksi yang rendah, yaitu sekitar 8 kali transaksi, rata-rata jumlah atau kuantitas produk yang dibeli customer rendah yaitu sekitar 27 unit produk, dan rata-rata jumlah uang yang dikeluarkan oleh customer rendah yaitu sekitar 229K.

Business Recommendation

Cluster 0 - Loyalty Customer: memberikan email khusus kepada customer atas keloyalitasan telah menggunakan produk dari company kami berupa ucapan terima kasih telah setia menggunakan produk kami dengan menyertakan reward voucher diskon berbelanja tanpa minimum pembelian beserta voucher gratis ongkir tanpa minimum pembelian dan dapat ditukarkan pada batas waktu tertentu.





Business Recommendation

- Cluster 1 Potential Customer: kelompok ini memiliki potensi untuk menjadi customer yang loyal menggunakan produk dari company. Hal yang dapat direkomendasikan berupa pemberian voucher diskon khusus pada produk yang sering dibeli oleh customer ini dengan voucher gratis ongkir dengan nol minimum pembelian dan dapat ditukarkan pada batas waktu tertentu.
- Cluster 2 New Customer: memberikan email khusus kepada customer dengan caption seperti "we miss you" agar kelompok ini bisa lebih sering berbelanja produk pada company kami dengan menyertakan reward voucher diskon berbelanja jika telah mencapai minimum pembelian yang telah ditentukan oleh company beserta voucher gratis ongkir jika mencapai minimum pembelian yang telah ditentukan oleh company juga dan dapat ditukarkan pada batas waktu tertentu.





Link Folder/Github/Video Presentation

Link Folder di Google Drive : disini

Link Github: disini

Link Video Presentation di Youtube: disini

Thank You





